

RAPORT FINAL

Problema si motivatia:

Tema proiectului este Clickbait Detection reprezentand o problema de clasificare care va returna daca textul dat este clickbait sau nu.

Corpusul si preprocesarea:

Corpusul problemei este compus din 32000 de exemple adnotate avand o distributie de ~50/50

Datele au fost impartite in 80% antrenare, 15% validare si 5% testare.

Tehnicile de preprocesarea textului au fost: lowercasing, tokenization, lemmatizare, eliminare stopwords, si eliminarea sibolurilor inutile.

! Nu s au folosit 6 tehnici de preprocesare deoarece le am considerat inutile in contextul meu, setul de date era deja "curat" , iar alte tehnici ar fi putut afecata rezultatele antrenarii propriu zise.

Descriere Modele:

In realizarea proiectului s au folosit 2 modele, svm si roberta.

SVM(Support Vector Machine):

Modelul a beneficiat de un lexicon feature custom pe baza celor mai multe cuvinte clickbait respectiv non clickbait

TF IDF Custom care penalizeaza cuvintele prin ajustarea scorului idf si limiteaza vocaularul la celele mai relevante feature uri

Svm ul are un kernel custom de grad 2 (3D) si o regularizare standard $C=1.0$

RoBerta:

Datele sunt procesate folosind RobertaTokenizer care transforma textul intr o secventa de tokeni aplicand padding si truncare.

Mecanism de Atterntion Custom, invata ponderile pt fiecare token ca modelul sa se focuseze pe cuvintele relevante pt identificare clickbait ului

Head Clasification custom

Pentru iesire s a adaugat un clasificator custom format di straturi fc cu f activare si dropout



Loss Function optimization Modelul a fost antrenat folosind o functie de loss custom bazata pe BCELoss pt ajustarea ponderilor. Are ca si optimizator AdamW si are un lr scheduler cu warmup

Rezultate Critice:

SVM

Val Classification Report				
Clasă	Precision	Recall	F1-score	Support
0	0.81	0.96	0.88	2400
1	0.95	0.78	0.85	2400
Accuracy			0.87	4800
Macro avg	0.88	0.87	0.87	4800
Weighted avg	0.88	0.87	0.87	4800

Test Classification Report				
Clasă	Precision	Recall	F1-score	Support
0	0.81	0.96	0.88	800
1	0.95	0.78	0.85	800
Accuracy			0.87	1600
Macro avg	0.88	0.87	0.87	1600
Weighted avg	0.88	0.87	0.87	1600



Macro-F1 Val 0.8662230711911936

Macro-F1 Test 0.8657417237927489


Val Precision 0.9472349061390157

Val Recall 0.7779166666666667

Test Precision 0.9494640122511485

Test Recall 0.775

PR-AUC Test 0.9675313348554835



RoBERTa

Validation Classification Report				
Class	Precision	Recall	F1-score	Support
0.0	0.97	0.97	0.97	2400
1.0	0.97	0.97	0.97	2400
Accuracy			0.97	4800
Macro avg	0.97	0.97	0.97	4800
Weighted avg	0.97	0.97	0.97	4800

Test Classification Report				
Class	Precision	Recall	F1-score	Support
0.0	0.97	0.97	0.97	800
1.0	0.97	0.97	0.97	800
Accuracy			0.97	1600
Macro avg	0.97	0.97	0.97	1600
Weighted avg	0.97	0.97	0.97	1600

Macro-F1 Val 0.969791088449219

Macro-F1 test 0.9712498203113769


Validation Precision 0.9657166460140438

Validation Recall 0.9741666666666666

Test Precision 0.9689054726368159

Test Recall 0.97375

PR-AUC (Test) 0.9963166779405092



Analiza Critica

Performanta Overall

Comparand ambele modele putem spune ca am obtinut o performanta cel putin satisfacatoare, dar exista diferente semnificative.

SVM are un Accuracy de 0.87 iar RoBERTa reuseste sa atinga 0.97, indicand o imbunatatire substantiala.

Macro F1

Diferenta este de aproximativ 10 puncte in favoarea modelului RoBERTa care indica o capacitate mult mai superioara de de clasificare pentru ambele clase.

Precision vs Recall

Chiar daca SVM are o precizie ridicata (0.95) recall ul este semnificativ mai scazut (0.78) asta denota ca rateaza multe instante pozitive. RoBERTa are un echilibru perfect intre precizie si Recall care reprezinta o capacitate superioara de generalizare.

PR_AUC

Chiar daca ambele modele au obtinut rezultate deosebit de bune RoBERTa se apropie de separarea aproape perfecta a claselor.

Stabilitate si generalizare

Ambele modele prezinta valori similare intre validare si testare ceea ce poate sugera absenta overfitting ului dar RoBERTa este mai stabil si ofera si performanta consistenta superioara.

Concluzie

Ambele modele au obtinut rezultate promitatoare si prezinta stabilitate dar RoBERTa depaseste semnificativ SVM in toate metricele relevante. RoBERTa este o alegere net superioara pentru sarcini unde acuratetea si recall ul sunt critice, chiar daca are costuri computationale mai mari.